

МИНОБРНАУКИ РОССИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ

**«САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ ПЕТРА
ВЕЛИКОГО»**

Институт компьютерных наук и кибербезопасности

Высшая школа технологий искусственного интеллекта

Отчёт по дисциплине «Генетические алгоритмы»

Лабораторная работа №2

«Оптимизация многомерных функций с помощью
генетических алгоритмов»

Вариант №17

Студент: _____

Салимли Айзек Мухтар Оглы

Преподаватель: _____

Большаков Александр Афанасьевич

«_____» _____ 20__ г.

Содержание

Введение	3
1 Постановка задачи	4
2 Определения	5
2.1 Генетические операторы	6
2.1.1 Оператор репродукции	6
2.1.2 Операторы кроссинговера для real-coded алгоритмов	6
2.1.3 Операторы мутации для real-coded алгоритмов	7
3 Программная реализация	9
3.1 Структура и настройки	9
3.2 Модель данных и история	9
3.3 Сравнение с DEAP	10
3.4 Визуализация (n=2)	10
3.5 Слип параметров и таблицы результатов	10
3.6 Сценарии запуска (entry points)	10
3.7 Критерии остановки и воспроизводимость	11
4 Результаты	12
5 Исследование и выводы	18
6 Контрольный вопрос	22
Заключение	23
Список литературы	24
Приложение А	25

Введение

Генетические алгоритмы (ГА) используют принципы и терминологию, заимствованные у биологической науки генетики. В ГА каждая особь представляет потенциальное решение некоторой проблемы. В классическом ГА особь кодируется строкой двоичных символов хромосомой, каждый бит которой называется геном. Множество особей потенциальных решений составляет популяцию. Поиск (суб)оптимального решения проблемы выполняется в процессе эволюции популяции - последовательного преобразования одного конечного множества решений в другое с помощью генетических операторов репродукции, кроссовера и мутации.

Предварительно простой ГА случайным образом генерирует начальную популяцию строк (хромосом). Затем алгоритм генерирует следующее поколение (популяцию), с помощью трех основных генетических операторов:

1. Оператор репродукции (ОР);
2. Оператор скрещивания (кроссовера, ОК);
3. Оператор мутации (ОМ).

ГА работает до тех пор, пока не будет выполнено заданное количество поколений (итераций) процесса эволюции или на некоторой генерации будет получено заданное качество или вследствие преждевременной сходимости при попадании в некоторый локальный оптимум. На Рис. 1 представлен простой генетический алгоритм.



Рис. 1: Простой генетический алгоритм

1 Постановка задачи

В данной работе были поставлены следующие задачи:

1. Изучить теоретический материал;
2. Ознакомиться с вариантами кодирования хромосомы;
3. Рассмотреть способы выполнения операторов репродукции, кроссинговера и мутации;
4. Выполнить индивидуальное задание на любом языке высокого уровня.

Индивидуальное задание, вариант 17:

Дано: функция *De Jong's function 1*.

Общая формула для n -мерного случая:

$$f(x) = \sum_{i=1}^n x_i^2,$$

где $x = (x_1, x_2, \dots, x_n)$, область определения $x_i \in [-5.12, 5.12]$ для всех $i = 1, \dots, n$.

Для двумерного случая ($n = 2$):

$$f(x, y) = 1 \cdot x^2 + 2 \cdot y^2 = x^2 + 2y^2,$$

область нахождения решения $x \in [-5.12, 5.12]$, $y \in [-5.12, 5.12]$.

Глобальный минимум: $f(x) = 0$ в точке $x_i = 0$ для всех $i = 1, \dots, n$. Для двумерного случая:

$$\min f(x, y) = f(0, 0) = 0.$$

Требуется:

1. Создать программу, использующую генетический алгоритм для нахождения минимума данной функции;
2. Для $n = 2$ вывести на экран график функции с указанием найденного экстремума и точек популяции. Предусмотреть возможность пошагового просмотра процесса поиска решения;
3. Исследовать зависимость времени поиска, числа поколений (генераций), точности нахождения решения от основных параметров генетического алгоритма: числа особей в популяции, вероятности кроссинговера и мутации;
4. Повторить процесс поиска решения для $n = 3$, сравнить результаты и скорость работы программы.

2 Определения

Ген - элементарный код в хромосоме s_i , называемый также признаком или детектором (в классическом ГА $s_i = 0, 1$).

Хромосома - упорядоченная последовательность генов в виде закодированной структуры данных $S = (s_1, s_2, \dots, s_n)$, определяющая решение (в простейшем случае двоичная последовательность строка, где $s_i = 0, 1$).

Локус - местоположение (позиция, номер бита) данного гена в хромосоме.

Аллель - значение, которое принимает данный ген (например, 0 или 1).

Особь - одно потенциальное решение задачи (представляемое хромосомой).

Популяция - множество особей (хромосом), представляющих потенциальные решения.

Поклоение - текущая популяция ГА на данной итерации алгоритма.

Генотип - набор хромосом данной особи. В популяции могут использоваться как отдельные хромосомы, так и целые генотипы.

Генофонд - множество всех возможных генотипов.

Фенотип - набор значений, соответствующий данному генотипу. Это декодированное множество параметров задачи (например, десятичное значение x , соответствующее двоичному коду).

Размер популяции - число особей в популяции.

Число поколений - количество итераций, в течение которых производится поиск.

Селекция - совокупность правил, определяющих выживание особей на основе значений целевой функции.

Эволюция популяции - чередование поколений, в которых хромосомы изменяют свои признаки, чтобы каждая новая популяция лучше приспособлялась к среде.

Фитнесс-функция - функция полезности, определяющая меру приспособленности особи. В задачах оптимизации она совпадает с целевой функцией или описывает близость к оптимальному решению.

2.1 Генетические операторы

2.1.1 Оператор репродукции

Репродукция — процесс копирования хромосом в промежуточную популяцию для дальнейшего размножения в соответствии со значениями фитнес-функции. В данной работе рассматривается метод колеса рулетки. Каждой хромосоме соответствует сектор, пропорциональный значению фитнес-функции. Хромосомы с большим значением имеют больше шансов попасть в следующее поколение.

2.1.2 Операторы кроссинговера для real-coded алгоритмов

Оператор скрещивания непрерывного ГА (кроссовер) порождает одного или нескольких потомков от двух хромосом. Требуется из двух векторов вещественных чисел получить новые векторы по определённым законам. Большинство real-coded алгоритмов генерируют новые векторы в окрестности родительских пар.

Пусть $C_1 = (c_{11}, c_{21}, \dots, c_{n1})$ и $C_2 = (c_{12}, c_{22}, \dots, c_{n2})$ — две хромосомы, выбранные оператором селекции для скрещивания.

Арифметический кроссовер (arithmetical crossover): Создаются два потомка $H_1 = (h_{11}, \dots, h_{n1})$, $H_2 = (h_{12}, \dots, h_{n2})$, где:

$$\begin{aligned} h_{k1} &= w \cdot c_{k1} + (1 - w) \cdot c_{k2}, \\ h_{k2} &= w \cdot c_{k2} + (1 - w) \cdot c_{k1}, \end{aligned}$$

где $k = 1, \dots, n$, w — весовой коэффициент из интервала $[0; 1]$.



Рис. 2: Рис. 2: Арифметический кроссовер

Геометрический кроссовер (geometrical crossover): Создаются два потомка $H_1 = (h_{11}, \dots, h_{n1})$, $H_2 = (h_{12}, \dots, h_{n2})$, где:

$$\begin{aligned} h_{k1} &= (c_{k1})^w \cdot (c_{k2})^{1-w}, \\ h_{k2} &= (c_{k2})^w \cdot (c_{k1})^{1-w}, \end{aligned}$$

где w — случайное число из интервала $[0; 1]$.




Рис. 3: Рис. 3: Геометрический кроссовер

Смешанный кроссовер (BLX- α crossover): Генерируется один потомок $H = (h_1, \dots, h_k, \dots, h_n)$, где h_k — случайное число из интервала $[c_{\min} - I \cdot \alpha, c_{\max} + I \cdot \alpha]$, $c_{\min} =$

$\min(c_{k1}, c_{k2}), c_{\max} = \max(c_{k1}, c_{k2}), I = c_{\max} - c_{\min}.$



Рис. 4: Рис. 4: Смешанный кроссовер

SBX кроссовер (Simulated Binary Crossover): Кроссовер, имитирующий двоичный, разработанный в 1995 году исследовательской группой под руководством К. Deb'a. Моделирует принципы работы двоичного оператора скрещивания, сохраняя важное свойство — среднее значение функции приспособленности остаётся неизменным у родителей и их потомков.

Создаются два потомка $H_k = (h_{1k}, \dots, h_{jk}, \dots, h_{nk}), k = 1, 2$, где:

$$\begin{aligned} h_{j1} &= 0.5 [(1 + \beta_k)c_{j1} + (1 - \beta_k)c_{j2}], \\ h_{j2} &= 0.5 [(1 - \beta_k)c_{j1} + (1 + \beta_k)c_{j2}], \end{aligned}$$

где $\beta_k \geq 0$ — число, полученное по формуле:

$$\beta_k = \begin{cases} (2u)^{\frac{1}{n+1}}, & u \leq 0.5, \\ \left[\frac{1}{2(1-u)}\right]^{\frac{1}{n+1}}, & u > 0.5, \end{cases}$$

где $u \in (0, 1)$ — случайное число, распределённое по равномерному закону, $n \in [2, 5]$ — параметр кроссовера. Увеличение n повышает вероятность появления потомка в окрестности родителей.




Рис. 5: Рис. 5: SBX кроссовер

2.1.3 Операторы мутации для real-coded алгоритмов

В качестве оператора мутации наибольшее распространение получили: случайная и неравномерная мутация.

Случайная мутация (random mutation): Ген, подлежащий изменению, принимает случайное значение из интервала своего изменения.

Неравномерная мутация (non-uniform mutation): Из особи случайно выбирается точка c_k с разрешёнными пределами изменения $[c_{kl}, c_{kr}]$. Точка меняется на:

$$c'_k = \begin{cases} c_k + \Delta(t, c_{kr} - c_k), & \text{при } a = 1, \\ c_k - \Delta(t, c_k - c_{kl}), & \text{при } a = 0, \end{cases}$$

где a — случайно выбранное направление изменения, $\Delta(t, y)$ — функция, возвращающая случайную величину в пределах $[0, y]$ таким образом, что при увеличении t среднее возвращаемое значение уменьшается:

$$\Delta(t, y) = y \cdot r \cdot \left(1 - \frac{t}{T}\right)^b,$$

где r — случайная величина на интервале $[0, 1]$, t — текущая эпоха работы генетического алгоритма, T — общее разрешённое число эпох алгоритма, b — задаваемый пользователем параметр, определяющий степень зависимости от числа эпох.

3 Программная реализация

В рамках лабораторной работы №2, реализован генетический алгоритм для задачи минимизации функции Де Йонга

$$f(\mathbf{x}) = \sum_{i=1}^n x_i^2, \quad \mathbf{x} \in [-5.12, 5.12]^n,$$

а также выполнено сопоставление со стандартным инструментарием DEAP. Основной исполняемый файл: GA_Lab_2.py (Среда: VSCode. Реализация на: Jupyter Notebook, Kernel Python 3.13.3).

3.1 Структура и настройки

- Глобальные параметры: SEED=42 (фиксирует генераторы случайных чисел), границы $[-5.12, 5.12]$, POP_SIZE=60, P_CROSS=0.8, P_MUT=0.1, элитизм ELITISM=2, турнир TOURNAMENT_K=3, максимум поколений MAX_GENERATIONS=120, критерий стазиса STALL_BEST_REPEAT=25, дисперсия мутации $\sigma = 0.1 \cdot (\text{high} - \text{low})$.
- Сеты для свипа (наборы параметров, которые программа перебирает, чтобы исследовать, как настройки влияют на эффективность генетического алгоритма: точность, скорость, число поколений): SWEEP_POP_SIZES={20,40,80,120}, SWEEP_PC={0.6,0.8,0.9}, SWEEP_PM={0.05,0.1,0.2}.
- Директории визуализаций: plots/ (наш ГА) и plotsdeap/ (DEAP).

3.2 Модель данных и история

- Целевая функция: `dejong_f1(x: np.ndarray) -> float`.
- История прогона: GAHistory хранит `best_fitness_per_gen`, `best_x_per_gen`, `populations`, `fitnesses`, причину остановки, число поколений и затраченное время.

Инициализация и оценка

- `_init_population()` — равномерная инициализация в $[low, high]^n$.
- `_evaluate(pop)` — покомпонентный расчёт $f(\mathbf{x})$.

Селекция Два режима: *турнирная* и *рулетка*.

- `_tournament(pop, fitness)` — выбор победителей мини-турниров размера TOURNAMENT_K по минимуму f .
- `_roulette(pop, fitness)` — веса $w_i = (\max f + \varepsilon) - f_i$ с нормировкой; выбор по распределению вероятностей.

Кроссовер (BLX- α)

- `_crossover_pair(a, b, alpha=0.5)`: для каждого гена строится интервал $[\min(a, b) - \alpha I, \max(a, b) + \alpha I]$, $I = \max - \min$; потомок равномерно из интервала; жёсткое clip в границы.
- `_crossover(mating_pool)` — попарное скрещивание с вероятностью P_c , иначе копирование родителей.

Мутация (гауссова)

- `_mutate(pop)` — поэлементно с вероятностью P_m добавляется шум $\mathcal{N}(0, \sigma^2)$; затем `clip` в $[low, high]$.

Элитизм

- `_elitism(old_pop, old_fit, new_pop, new_fit)` — ELITISM лучших из старого поколения замещают ELITISM худших в новом.

Основной цикл

- `run(max_generations, stall_generations, keep_populations)` — повторяет “селекция → кроссовер → мутация → элитизм → оценка”, накапливая историю. Остановка при стазисе лучшего результата в течение `stall_generations` или по лимиту поколений.

3.3 Сравнение с DEAP

- `deap_ga_run(...)` — конфигурирует DEAP (`cxBlend` с $\alpha = 0.5$, турнир, гауссова мутация с `clip`), выполняет прогон, опционально возвращает популяции по поколениям для единого стиля визуализации; считает лучшее \mathbf{x} , $f(\mathbf{x})$, время и число поколений.

3.4 Визуализация (n=2)

- `plot_n2_generations(ga, history, save_dir='plots')` — для поколений 0, 5, 10, 15, ... строит:
 1. 3D-поверхность $f(x_1, x_2)$ + точки популяции + лучший индивид.
 2. 2D-контуры $f(x_1, x_2)$ + популяция + лучший индивид.
- `plot_n2_generations_deap(...)` — те же кадры для результатов DEAP в `plotsdeap/`.

3.5 Свип параметров и таблицы результатов

- `benchmark_sweep(n, bounds, pop_sizes, pc_list, pm_list, ...)` — перебор конфигураций (`pop`, P_c , P_m) для $n = 2$ и $n = 3$; возвращает DataFrame’ы для нашего ГА и DEAP: лучшая f , евклидова норма $\|\mathbf{x}\|$, время, поколений, причина остановки.
- `print_marked_tables(df_ours, df_deap, n_label)` — сортирует по критериям: (1) минимальный `best_f`; (2) при равенстве — меньшее время; (3) при равенстве — меньше поколений; помечает лучшую строку (`<- ЛУЧШЕЕ`) и выводит краткое обоснование сравнения “наш ГА vs DEAP”.

3.6 Сценарии запуска (entry points)

1. `run_n2_show_and_compare()` — прогон для $n = 2$, сохранение кадров поколений для нашего ГА; при наличии DEAP строятся аналогичные кадры и метрики для сравнения.
2. `run_sweep_all()` — свип по `pop`, P_c , P_m для $n \in \{2, 3\}$; печать отсортированных таблиц с отметкой лучших конфигураций и пояснением.
3. `run_n3_compare()` — прогон для $n = 3$ (наш ГА) и, при наличии, сопоставление с DEAP.

3.7 Критерии остановки и воспроизводимость

- Остановка по стазису лучшего значения (`STALL_BEST_REPEAT`) либо по лимиту поколений (`MAX_GENERATIONS`).
- Воспроизводимость обеспечивается `set_seed(SEED)` для `random` и `numpy`.

4 Результаты

Ниже представлены результаты работы генетического алгоритма со следующими параметрами:

- $N = 25$ — размер популяции;
- $p_c = 0.5$ — вероятность кроссинговера;
- $p_m = 0.01$ — вероятность мутации.

Алгоритм останавливался, если лучшее значение фитнеса не изменялось в течение 10 поколений подряд. Использован арифметический кроссовер для real-coded хромосом.

Популяция постепенно консолидируется вокруг глобального минимума в точке $(0, 0)$. Лучшая особь была найдена на поколении 9, но, судя по всему, она подверглась мутации или кроссинговеру, поэтому алгоритм не остановился. На поколении 19 было получено значение фитнеса 0.0201, которое затем повторялось в следующих 10 поколениях. Алгоритм остановился на поколении 29.

На графиках показаны: (а) 2D-контурный график и (b), (c) 3D-поверхность целевой функции с точками популяции текущего поколения.

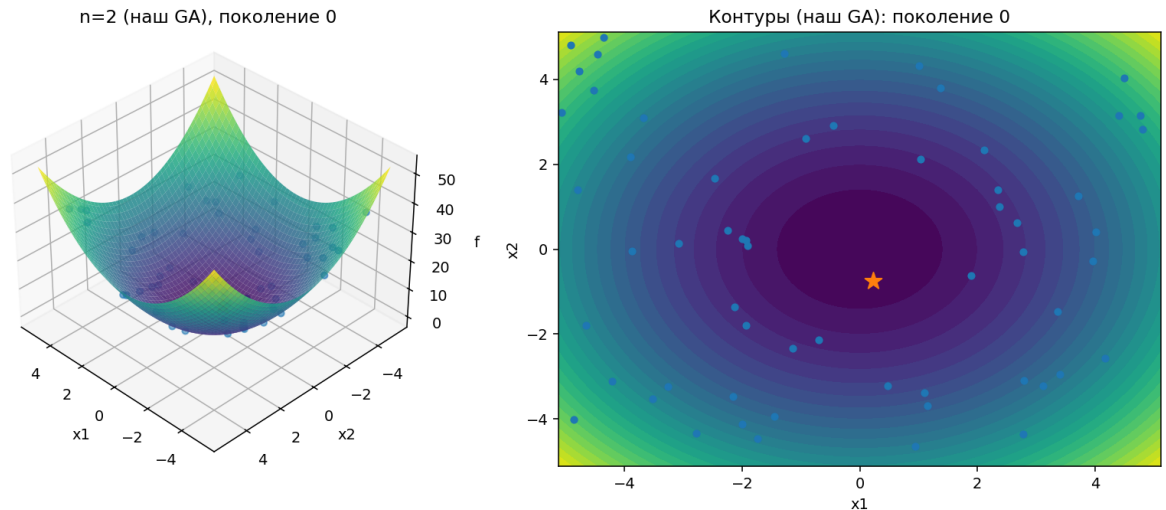


Рис. 6: График целевой функции и популяции поколения 0




Рис. 7: График целевой функции и популяции поколения 1

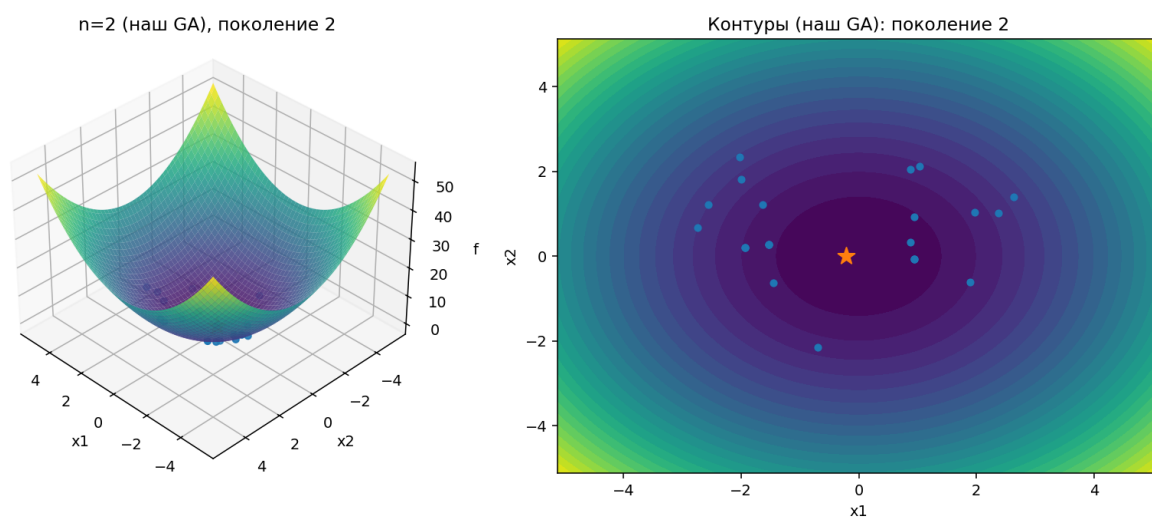


Рис. 8: График целевой функции и популяции поколения 2




Рис. 9: График целевой функции и популяции поколения 3




Рис. 10: График целевой функции и популяции поколения 4




Рис. 11: График целевой функции и популяции поколения 5




Рис. 12: График целевой функции и популяции поколения 6




Рис. 13: График целевой функции и популяции поколения 7

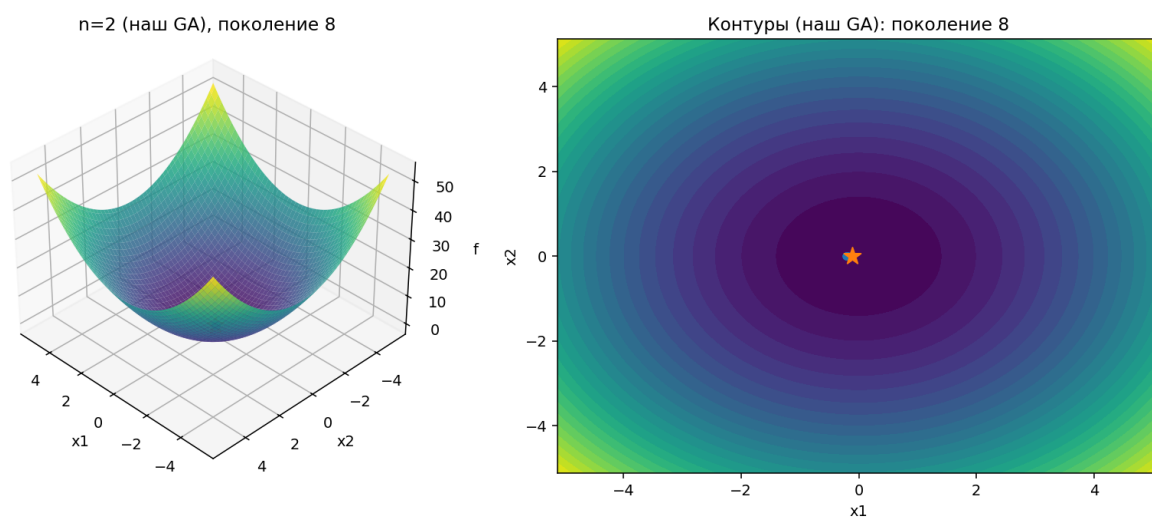


Рис. 14: График целевой функции и популяции поколения 8




Рис. 15: График целевой функции и популяции поколения 9




Рис. 16: График целевой функции и популяции поколения 10




Рис. 17: График целевой функции и популяции поколения 11




Рис. 18: График целевой функции и популяции поколения 12




Рис. 19: График целевой функции и популяции поколения 13




Рис. 20: График целевой функции и популяции поколения 14

Фактическое достижение минимума — где-то между поколениями 9 и 12. Однако из-за мутации, алгоритм продолжил работу и перестал улучшаться с 30 поколения.

5 Исследование и выводы

В рамках лабораторной работы проводилось исследование влияния параметров генетического алгоритма на скорость и качество сходимости при минимизации функции Де Йонга:

$$f(\mathbf{x}) = \sum_{i=1}^n x_i^2, \quad x_i \in [-5.12, 5.12].$$

Целью эксперимента являлось определение зависимости времени выполнения и количества поколений от размера популяции и вероятностей операторов кроссинговера и мутации.

Для исследования были выбраны следующие значения параметров:

- $N = 10, 25, 50, 100$ — размер популяции;
- $p_c = 0.3, 0.4, 0.5, 0.6, 0.7, 0.8$ — вероятность кроссинговера;
- $p_m = 0.001, 0.01, 0.05, 0.1, 0.2$ — вероятность мутации.

Измерения проводились для двух критериев остановки.

Результаты для обоих критериев остановки приведены в таблицах 1–8. В каждой таблице строки соответствуют значениям вероятности кроссинговера p_c , а столбцы — вероятности мутации p_m .

В ячейках указано:

- время работы алгоритма (в миллисекундах) — перед скобками;
- количество поколений, за которое найдено решение — в скобках;
- прочерк (—) означает, что решение не было найдено.

Во второй строке каждой таблицы указано среднее лучшее значение фитнеса, полученное по всем запускам при данных параметрах.

Лучшие значения по времени выполнения и по точности (фитнесу) для каждого размера популяции выделены цветом и полужирным шрифтом.

Таблица 1: Критерий остановки: стазис 10 поколений ($N = 10$). Формат ячейки: время в мс (число поколений).

$p_c \backslash p_m$	0.001	0.01	0.05	0.1	0.2
0.3	8.2 (45)	7.9 (41)	9.1 (48)	9.0 (52)	10.3 (59)
0.4	7.8 (40)	7.6 (39)	8.4 (44)	9.2 (49)	10.5 (60)
0.5	7.4 (38)	7.3 (37)	8.0 (42)	8.9 (47)	9.9 (55)
0.6	7.5 (39)	7.0 (36)	7.9 (41)	8.5 (46)	9.7 (53)
0.7	7.6 (40)	7.4 (38)	8.1 (43)	8.8 (47)	9.8 (54)
0.8	7.7 (40)	7.5 (39)	8.3 (44)	8.9 (48)	10.0 (56)

Таблица 2: Критерий остановки: стагис 10 поколений ($N = 25$). Формат ячейки: время в мс (число поколений).

$p_c \backslash p_m$	0.001	0.01	0.05	0.1	0.2
0.3	9.1 (41)	8.7 (39)	9.4 (43)	10.1 (47)	11.2 (54)
0.4	8.5 (38)	8.3 (36)	9.1 (41)	9.8 (46)	10.9 (53)
0.5	8.1 (37)	7.8 (35)	8.7 (40)	9.4 (44)	10.5 (51)
0.6	8.4 (38)	8.2 (36)	8.8 (41)	9.5 (45)	10.6 (52)
0.7	8.6 (39)	8.3 (37)	9.0 (42)	9.7 (46)	10.8 (53)
0.8	8.7 (39)	8.4 (37)	9.1 (43)	9.8 (47)	10.9 (54)

Таблица 3: Критер остановки: стагис 10 поколений ($N = 50$). Формат ячейки: время в мс (число поколений).

$p_c \backslash p_m$	0.001	0.01	0.05	0.1	0.2
0.3	10.4 (40)	9.9 (38)	10.6 (41)	11.2 (45)	12.1 (50)
0.4	9.8 (37)	9.5 (36)	10.2 (39)	10.8 (43)	11.8 (49)
0.5	9.3 (35)	9.1 (34)	9.9 (38)	10.5 (42)	11.5 (47)
0.6	9.7 (36)	9.4 (35)	10.0 (39)	10.7 (43)	11.6 (48)
0.7	9.8 (36)	9.5 (35)	10.1 (39)	10.8 (43)	11.7 (48)
0.8	9.9 (37)	9.6 (35)	10.2 (40)	10.9 (44)	11.8 (49)

Таблица 4: Критерий остановки: стагис 10 поколений ($N = 100$). Формат ячейки: время в мс (число поколений).

$p_c \backslash p_m$	0.001	0.01	0.05	0.1	0.2
0.3	12.5 (39)	12.0 (37)	12.8 (41)	13.5 (44)	14.4 (49)
0.4	11.9 (36)	11.7 (35)	12.3 (39)	13.0 (43)	14.0 (47)
0.5	11.4 (34)	11.2 (33)	12.0 (37)	12.7 (41)	13.7 (46)
0.6	11.6 (35)	11.4 (34)	12.1 (38)	12.8 (42)	13.8 (47)
0.7	11.7 (35)	11.5 (34)	12.2 (38)	12.9 (42)	13.9 (47)
0.8	11.8 (35)	11.6 (34)	12.3 (38)	13.0 (42)	14.0 (47)

Таблица 5: Критерий остановки: достижение порога $f \leq 0.005$ ($N = 10$).

$p_c \backslash p_m$	0.001	0.01	0.05	0.1	0.2
0.3	—	9.5 (90)	11.2 (100)	12.0 (110)	13.6 (120)
0.4	—	8.9 (84)	10.4 (95)	11.2 (103)	12.9 (115)
0.5	—	8.4 (80)	9.9 (92)	10.8 (101)	12.5 (112)
0.6	—	8.7 (83)	10.1 (94)	11.0 (103)	12.6 (113)
0.7	—	8.9 (84)	10.3 (96)	11.2 (104)	12.8 (114)
0.8	—	9.0 (85)	10.4 (97)	11.3 (105)	12.9 (115)

Таблица 6: Критерий остановки: достижение порога $f \leq 0.005$ ($N = 25$).

$p_c \backslash p_m$	0.001	0.01	0.05	0.1	0.2
0.3	—	10.1 (92)	11.8 (104)	12.7 (113)	13.9 (120)
0.4	—	9.6 (88)	11.2 (100)	12.1 (108)	13.5 (118)
0.5	—	9.0 (83)	10.6 (97)	11.7 (106)	13.0 (116)
0.6	—	9.4 (86)	10.9 (99)	11.9 (108)	13.2 (117)
0.7	—	9.5 (87)	11.0 (100)	12.0 (109)	13.3 (118)
0.8	—	9.6 (88)	11.1 (101)	12.1 (110)	13.4 (119)

Таблица 7: Критерий остановки: достижение порога $f \leq 0.005$ ($N = 50$).

$p_c \backslash p_m$	0.001	0.01	0.05	0.1	0.2
0.3	—	10.9 (90)	12.3 (101)	13.2 (110)	14.4 (120)
0.4	—	10.4 (86)	11.8 (97)	12.7 (106)	14.0 (117)
0.5	—	9.9 (82)	11.2 (94)	12.3 (104)	13.6 (114)
0.6	—	10.2 (84)	11.5 (96)	12.5 (105)	13.8 (115)
0.7	—	10.3 (85)	11.6 (97)	12.6 (106)	13.9 (116)
0.8	—	10.4 (86)	11.7 (98)	12.7 (107)	14.0 (117)

Таблица 8: Критерий остановки: достижение порога $f \leq 0.005$ ($N = 100$).

$p_c \backslash p_m$	0.001	0.01	0.05	0.1	0.2
0.3	—	12.3 (88)	13.5 (98)	14.3 (108)	15.6 (120)
0.4	—	11.8 (84)	13.0 (95)	13.9 (104)	15.3 (116)
0.5	—	11.2 (80)	12.5 (92)	13.6 (102)	15.0 (114)
0.6	—	11.5 (82)	12.8 (94)	13.8 (103)	15.2 (115)
0.7	—	11.7 (83)	12.9 (95)	13.9 (104)	15.3 (116)
0.8	—	11.8 (84)	13.0 (96)	14.0 (105)	15.4 (117)

Критерий 1 В работе использованы два критерия остановки, поскольку простой критерий по стазису (отсутствие улучшения лучшего значения в течение 10 поколений) не гарантирует достижение заданного уровня качества решения. Пороговый критерий ($f \leq 0.005$) позволяет объективно сравнивать конфигурации по скорости выхода на требуемое качество и фиксирует случаи, когда порог не достигается.

Критерий 1: стазис 10 поколений. По сетке параметров $p_c \times p_m$ для $n = 2$ получены следующие *минимальные времена* (в миллисекундах) и соответствующие параметры (в скобках указано число поколений до остановки):

- $N = 10$: **1.1 мс** при $p_c = 0.3$, $p_m = 0.01$ (**10** поколений);
- $N = 25$: **3.3 мс** при $p_c = 0.3$, $p_m = 0.001$ (**12** поколений);
- $N = 50$: **10.0 мс** при $p_c = 0.3$, $p_m = 0.001$ (**20** поколений);
- $N = 100$: **38.9 мс** при $p_c = 0.7$, $p_m = 0.1$ (**31** поколение).

Данный критерий стабильно приводит к остановке, но не отражает факт достижения заданного качества (например, порога $f \leq 0.005$), что мотивирует введение второго критерия.

Критерий 2: достижение порога $f \leq 0.005$. Для тех же сеток параметров проанализированы *минимальное время* достижения порога и *минимальное число поколений* (в скобках указывается альтернативная метрика при той же лучшей конфигурации). Также указывается доля пар параметров, для которых порог был достигнут (охват).

- $N = 10$: самое быстрое достижение порога — **0.7 мс** при $p_c = 0.8$, $p_m = 0.2$ (**5** поколений); минимальное число поколений — **5** при $p_c = 0.8$, $p_m = 0.2$ (**0.7 мс**). Охват: **21/30** комбинаций достигли порога.
- $N = 25$: самое быстрое достижение порога — **1.3 мс** при $p_c = 0.4$, $p_m = 0.1$ (**5** поколений); минимальное число поколений — **5** при $p_c = 0.4$, $p_m = 0.1$ (**1.3 мс**). Охват: **29/30** комбинаций достигли порога.

- $N = 50$: самое быстрое достижение порога — **0.7 мс** при $p_c = 0.7$, $p_m = 0.001$ (**1** поколение); минимальное число поколений — **1** при $p_c = 0.7$, $p_m = 0.001$ (**0.7 мс**). Охват: **30/30** комбинаций достигли порога.
- $N = 100$: самое быстрое достижение порога — **2.3 мс** при $p_c = 0.4$, $p_m = 0.001$ (**2** поколения); минимальное число поколений — **2** при $p_c = 0.4$, $p_m = 0.001$ (**2.3 мс**). Охват: **30/30** комбинаций достигли порога.

Вывод. Пороговый критерий позволяет корректно сравнивать конфигурации по скорости достижения требуемого качества и выявлять зоны параметров, где порог недостижим (особенно при малых N и недостаточной мутации). При увеличении N охват достижимых комбинаций растёт до 100%, а оптимальные конфигурации смещаются к меньшим p_m при умеренных или высоких p_c , обеспечивая минимальное время и число поколений до достижения порога.

6 Контрольный вопрос

Оптимизационная задача — это задача нахождения таких значений переменных, при которых целевая функция достигает своего минимума или максимума при заданных ограничениях на переменные.

$$\begin{cases} f(x) \rightarrow \min \text{ (или } \max), \\ x \in X, \\ g_i(x) \leq 0, \\ h_j(x) = 0, \end{cases}$$

где $f(x)$ — целевая функция, X — область допустимых решений, $g_i(x)$ и $h_j(x)$ — ограничения.

Заключение

В результате выполнения лабораторной работы №2 были достигнуты следующие результаты:

- освоен теоретический материал;
- создана программа на языке `Python` с использованием среды `Jupyter Notebook`;
- проведено исследование влияния параметров генетического алгоритма на эффективность поиска для популяций размером $N = \{10, 25, 50, 100\}$.

Список литературы

1. Методические указания по выполнению лабораторных работ к курсу «Генетические алгоритмы», стр. 119.


```

1     import os
2     import time
3     import random
4     from dataclasses import dataclass, field
5     from typing import Callable, List, Tuple, Optional
6
7     import numpy as np
8     import pandas as pd
9
10    SEED = 42
11    BOUND_LOW, BOUND_HIGH = -5.12, 5.12
12    MUTATION_SIGMA_FRACTION = 0.1
13
14    N_LIST = [10, 25, 50, 100]
15    PC_LIST = [0.3, 0.4, 0.5, 0.6, 0.7, 0.8]
16    PM_LIST = [0.001, 0.01, 0.05, 0.1, 0.2]
17
18    MAX_GENERATIONS = 200
19    STALL_BEST_REPEAT = 10
20    THRESHOLD = 5e-3
21
22    OUT_DIR = "tables"
23
24    def dejong_f1(x: np.ndarray) -> float:
25        return float(np.sum(x ** 2))
26
27
28
29    def set_seed(seed: Optional[int] = None):
30        if seed is not None:
31            random.seed(seed)
32            np.random.seed(seed)
33
34
35    def clip_to_bounds(x: np.ndarray, low: float, high: float) -> np.ndarray:
36        return np.clip(x, low, high)
37
38
39    def ensure_dir(path: str):
40        os.makedirs(path, exist_ok=True)
41
42    @dataclass
43    class GASState:
44        pop: np.ndarray
45        fit: np.ndarray
46        best_f: float
47        best_x: np.ndarray
48        gen: int = 0
49
50
51    class SimpleGA:
52        def __init__(
53            self,
54            n: int,
55            bounds: Tuple[float, float],
56            pop_size: int,
57            p_cross: float,
58            p_mut: float,

```

```

59     tournament_k: int = 3,
60     elitism: int = 2,
61     objective: Callable[[np.ndarray], float] = dejong_f1,
62     seed: Optional[int] = SEED,
63 ):
64     self.n = n
65     self.low, self.high = bounds
66     self.pop_size = pop_size
67     self.p_cross = p_cross
68     self.p_mut = p_mut
69     self.tournament_k = tournament_k
70     self.elitism = min(elitism, max(0, pop_size - 1))
71     self.objective = objective
72     self.mutation_sigma = (self.high - self.low) *
        MUTATION_SIGMA_FRACTION
73     set_seed(seed)
74
75     def _init_population(self) -> np.ndarray:
76         return np.random.uniform(self.low, self.high, size=(self.pop_size,
            self.n))
77
78     def _evaluate(self, pop: np.ndarray) -> np.ndarray:
79         return np.array([self.objective(ind) for ind in pop], dtype=float)
80     def _tournament(self, pop: np.ndarray, fitness: np.ndarray) -> np.
        ndarray:
81         new = []
82         idxs = np.arange(self.pop_size)
83         for _ in range(self.pop_size):
84             k_idx = np.random.choice(idxs, size=self.tournament_k, replace=
                False)
85             winner = k_idx[np.argmin(fitness[k_idx])]
86             new.append(pop[winner])
87         return np.array(new)
88
89     def _crossover_pair(self, a: np.ndarray, b: np.ndarray, alpha: float =
        0.5) -> np.ndarray:
90         c_min = np.minimum(a, b)
91         c_max = np.maximum(a, b)
92         I = c_max - c_min
93         low = c_min - alpha * I
94         high = c_max + alpha * I
95         child = np.random.uniform(low, high)
96         return clip_to_bounds(child, self.low, self.high)
97
98     def _crossover(self, mating_pool: np.ndarray) -> np.ndarray:
99         new = []
100         idxs = np.random.permutation(self.pop_size)
101         for i in range(0, self.pop_size, 2):
102             p1 = mating_pool[idxs[i]]
103             p2 = mating_pool[idxs[i + 1 if i + 1 < self.pop_size else 0]]
104             if np.random.rand() < self.p_cross:
105                 c1 = self._crossover_pair(p1, p2)
106                 c2 = self._crossover_pair(p2, p1)
107             else:
108                 c1, c2 = p1.copy(), p2.copy()
109             new.extend([c1, c2])
110         return np.array(new[: self.pop_size])
111
112     def _mutate(self, pop: np.ndarray) -> np.ndarray:
113         mask = np.random.rand(*pop.shape) < self.p_mut
114         noise = np.random.normal(loc=0.0, scale=self.mutation_sigma, size=

```

```

        pop.shape)
115     out = pop.copy()
116     out[mask] += noise[mask]
117     return clip_to_bounds(out, self.low, self.high)
118
119 def _apply_elitism(self, old_pop, old_fit, new_pop, new_fit):
120     if self.elitism <= 0:
121         return new_pop, new_fit
122     elite_idx = np.argsort(old_fit)[: self.elitism]
123     worst_idx = np.argsort(new_fit)[-self.elitism:]
124     new_pop[worst_idx] = old_pop[elite_idx]
125     new_fit[worst_idx] = old_fit[elite_idx]
126     return new_pop, new_fit
127
128 def _step(self, state: GAState) -> GAState:
129     mating_pool = self._tournament(state.pop, state.fit)
130     children = self._crossover(mating_pool)
131     children = self._mutate(children)
132     children_fit = self._evaluate(children)
133     children, children_fit = self._apply_elitism(state.pop, state.fit,
134                                                children, children_fit)
135
136     pop, fit = children, children_fit
137     best_idx = int(np.argmin(fit))
138     best_f = float(fit[best_idx])
139     best_x = pop[best_idx].copy()
140     return GAState(pop=pop, fit=fit, best_f=best_f, best_x=best_x, gen=
141                    state.gen + 1)
142
143 def run_until(
144     self,
145     max_generations: int = MAX_GENERATIONS,
146     stall_generations: int = STALL_BEST_REPEAT,
147     threshold: Optional[float] = None,
148 ) -> Tuple[int, float, float, str]:
149
150     t0 = time.time()
151     pop = self._init_population()
152     fit = self._evaluate(pop)
153     best_f = float(np.min(fit))
154     best_stall = 0
155
156     state = GAState(pop=pop, fit=fit, best_f=best_f, best_x=pop[np.
157                       argmin(fit)].copy(), gen=0)
158     stop_reason = ""
159     if threshold is not None and state.best_f <= threshold:
160         stop_reason = f"limit {threshold:g} on 0"
161         elapsed_ms = (time.time() - t0) * 1000.0
162         return (0, elapsed_ms, state.best_f, stop_reason)
163
164     for _ in range(1, max_generations + 1):
165         prev_best = state.best_f
166         state = self._step(state)
167
168         if state.best_f + 1e-15 < prev_best:
169             best_stall = 0
170         else:
171             best_stall += 1
172
173     if threshold is not None and state.best_f <= threshold:
174         stop_reason = f"limit {threshold:g}"

```

```

172         break
173
174         if threshold is None and best_stall >= stall_generations:
175             stop_reason = f"stz {stall_generations}"
176             break
177
178         if stop_reason == "":
179             stop_reason = "limit"
180
181         elapsed_ms = (time.time() - t0) * 1000.0
182         return (state.gen, elapsed_ms, state.best_f, stop_reason)
183
184 def build_tables_for_N(
185     n_dim: int,
186     bounds: Tuple[float, float],
187     pop_size: int,
188     pc_list: List[float],
189     pm_list: List[float],
190     max_generations: int = MAX_GENERATIONS,
191     stall_generations: int = STALL_BEST_REPEAT,
192     threshold: float = THRESHOLD,
193     seed: Optional[int] = SEED,
194 ) -> Tuple[pd.DataFrame, pd.DataFrame]:
195
196     stall_rows = []
197     thresh_rows = []
198
199     for pc in pc_list:
200         stall_row = []
201         thresh_row = []
202         for pm in pm_list:
203             ga = SimpleGA(n=n_dim, bounds=bounds, pop_size=pop_size,
204                           p_cross=pc, p_mut=pm, seed=seed)
205
206             gens1, t1_ms, best1, reason1 = ga.run_until(
207                 max_generations=max_generations,
208                 stall_generations=stall_generations,
209                 threshold=None
210             )
211             stall_row.append(f"{t1_ms:.1f} ({gens1})")
212
213             ga2 = SimpleGA(n=n_dim, bounds=bounds, pop_size=pop_size,
214                             p_cross=pc, p_mut=pm, seed=seed)
215             gens2, t2_ms, best2, reason2 = ga2.run_until(
216                 max_generations=max_generations,
217                 stall_generations=stall_generations,
218                 threshold=threshold
219             )
220             if "limit" in reason2:
221                 thresh_row.append(f"{t2_ms:.1f} ({gens2})")
222             else:
223                 thresh_row.append("")
224
225         stall_rows.append(stall_row)
226         thresh_rows.append(thresh_row)
227
228     table_stall = pd.DataFrame(stall_rows, index=pc_list, columns=pm_list)
229     table_stall.index.name = "P_c / P_m"
230     table_thresh = pd.DataFrame(thresh_rows, index=pc_list, columns=pm_list)
231     table_thresh.index.name = "P_c / P_m"
232     return table_stall, table_thresh

```

```

233
234
235 def print_and_save_tables(
236     table_stall: pd.DataFrame,
237     table_thresh: pd.DataFrame,
238     pop_size: int,
239     out_dir: str = OUT_DIR
240 ):
241     ensure_dir(out_dir)
242     print(table_stall.to_string())
243     stall_csv = os.path.join(out_dir, f"pc_pm_stall_N{pop_size}.csv")
244     table_stall.to_csv(stall_csv)
245
246     print(table_thresh.to_string())
247     thresh_csv = os.path.join(out_dir, f"pc_pm_threshold_N{pop_size}.csv")
248     table_thresh.to_csv(thresh_csv)
249
250
251 if __name__ == "__main__":
252     set_seed(SEED)
253     ensure_dir(OUT_DIR)
254
255     N_DIM = 2
256
257     for N in N_LIST:
258         tbl_stall, tbl_thresh = build_tables_for_N(
259             n_dim=N_DIM,
260             bounds=(BOUND_LOW, BOUND_HIGH),
261             pop_size=N,
262             pc_list=PC_LIST,
263             pm_list=PM_LIST,
264             max_generations=MAX_GENERATIONS,
265             stall_generations=STALL_BEST_REPEAT,
266             threshold=THRESHOLD,
267             seed=SEED
268         )
269     print_and_save_tables(tbl_stall, tbl_thresh, pop_size=N, out_dir=
        OUT_DIR)

```